

## گزارش بررسی روش‌های اندازه‌گیری سرعت جریان آب رودخانه‌ها مبتنی بر پردازش تصویر

---

### ۱. مقدمه

هدف این پروژه، ارائه روشی برای تخمین سرعت جریان آب رودخانه بر اساس ویدئوهای ثبت‌شده از سطح آب و مقادیر واقعی سرعت جریان بود. در این مسئله، ورودی اصلی شامل مجموعه‌ای از ویدئوهای جریان آب در شرایط مختلف تصویربرداری است و خروجی مورد انتظار، تخمین سرعت جریان آب بر حسب متر بر ثانیه برای هر ویدئو است.

با توجه به ماهیت مسئله، چند چالش اصلی از ابتدا وجود داشت: تعداد کم ویدئوهای دارای مقدار واقعی سرعت، تفاوت زیاد شرایط تصویربرداری، نبود اطلاعات کالیبراسیون فیزیکی مانند مقیاس تصویر، زاویه دوربین و ارتفاع دوربین، و همچنین وجود نویزهای محیطی مانند حرکت درختان، بازتاب نور، ناپایداری دوربین، تصاویر حرارتی و تفاوت در سنسورهای تصویربرداری.

به همین دلیل، در این پروژه به‌جای استفاده مستقیم از یک مدل یادگیری عمیق سنگین، ابتدا از روش‌های قابل توضیح پردازش تصویر برای استخراج ویژگی‌های حرکتی سطح آب استفاده شد و سپس این ویژگی‌ها به یک مدل رگرسیون یادگیری ماشین داده شدند تا رابطه بین حرکت تصویری و سرعت واقعی جریان یاد گرفته شود.

روش نهایی پروژه بر پایه ترکیب موارد زیر طراحی شد:

Optical Flow + KLT Feature Tracking + Window-based Feature Extraction + Metadata Features + RandomForest Regression

---

### ۲. بررسی اولیه دیتاست

دیتاست شامل ۲۴ ویدئو از جریان آب رودخانه بود. از میان این ویدئوها، ۲۲ ویدئو دارای مقدار واقعی سرعت جریان آب بودند و ۲ ویدئو مقدار واقعی سرعت نداشتند. بنابراین، ۲۲ ویدئو برای آموزش و ارزیابی مدل استفاده شدند و ۲ ویدئوی بدون برچسب فقط در مرحله نهایی توسط مدل آموزش‌دیده پیش‌بینی شدند.

ویدئوهای دیتاست از نظر شرایط تصویربرداری کاملاً یکسان نبودند. برخی از آن‌ها از بالا و تقریباً عمود بر سطح آب ثبت شده بودند، برخی با زاویه مایل، برخی در محیط کنترل‌شده‌تر، برخی در رودخانه واقعی با پوشش گیاهی، برخی با سنسور حرارتی یا FLIR، و برخی دارای نویز، چرخش، لرزش یا ناپایداری دوربین بودند.

مقدار سرعت واقعی ویدئوهای دارای برچسب نیز بازه گسترده‌ای را پوشش می‌داد؛ از حدود ۰.۱۴۱ متر بر ثانیه تا ۶.۰۰۱ متر بر ثانیه. این اختلاف زیاد در مقدار سرعت، در کنار تعداد کم نمونه‌ها، باعث شد مسئله از نظر یادگیری ماشین با چالش جدی روبه‌رو باشد.

---

### ۳. چالش‌های اصلی دیتاست

در بررسی اولیه ویدئوها، چالش‌های زیر شناسایی شد:

۱.۳. تعداد کم نمونه‌های برچسب‌دار

تنها ۲۲ ویدئوی دارای مقدار واقعی سرعت در اختیار بود. این تعداد برای آموزش مدل‌های یادگیری عمیق بسیار کم است و حتی برای مدل‌های یادگیری ماشین نیز باعث محدودیت در تعمیم‌پذیری مدل می‌شود.

۲.۳. ناهمگونی شدید شرایط تصویربرداری

ویدئوها از رودخانه‌ها و محیط‌های مختلف ثبت شده بودند. تفاوت در زاویه دوربین، ارتفاع دوربین، نوع سنسور، نور محیط، کیفیت تصویر و وجود اشیای مزاحم باعث ایجاد Domain Shift میان نمونه‌ها شد.

۳.۳. نبود کالیبراسیون فیزیکی

اطلاعاتی مانند GSD، مقیاس تصویر، ارتفاع دوربین، زاویه دوربین یا نقاط مرجع مکانی در اختیار نبود. بنابراین امکان تبدیل مستقیم جابه‌جایی پیکسلی به سرعت واقعی بر حسب متر بر ثانیه وجود نداشت. به همین دلیل، مدل باید رابطه بین ویژگی‌های حرکتی تصویری و سرعت واقعی را از داده‌های موجود یاد می‌گرفت.

۴.۳. وجود نویز محیطی

در برخی ویدئوها، حرکت درختان در اثر باد، بازتاب نور روی سطح آب، نویز تصویری، تغییرات روشنایی، حرکت افراد یا اشیای کنار رودخانه، و همچنین نمودار یا colorbar در تصاویر حرارتی مشاهده شد. این موارد می‌توانند باعث شوند الگوریتم Optical Flow حرکت‌هایی را استخراج کند که مربوط به جریان آب نیستند.

۵.۳. تفاوت نوع ویدئوها

برخی ویدئوها seeded بودند، یعنی ذرات یا نقاط قابل ردیابی روی سطح آب وجود داشت. برخی دیگر unseeded بودند و سطح آب بافت حرکتی مشخصی نداشت. در برخی ویدئوها نیز تصویر بسیار تیره بود و فقط نقاط روشن یا الگوهای محدود قابل ردیابی بودند.

۶.۳. وجود نمونه‌های پرت یا دشوار

ویدئوهایی مانند StJulien، Tiber و Thalhofen سرعت بالاتری نسبت به بخش عمده داده‌ها داشتند. به خصوص StJulien با سرعت واقعی  $6.001 \text{ m/s}$  از نظر مقدار سرعت یک نمونه بسیار متفاوت نسبت به سایر داده‌ها بود. مدل‌های درختی مانند RandomForest معمولاً در برون‌یابی خارج از محدوده داده‌های آموزشی عملکرد ضعیف‌تری دارند؛ بنابراین پیش‌بینی این نمونه‌ها دشوارتر بود.



#### ۴. پیش پردازش ویدئوها

برای آماده سازی ویدئوها، مراحل زیر انجام شد:

۱. خواندن ویدئوها با استفاده از OpenCV
۲. نمونه برداری از فریم ها با نرخ مشخص، برای کنترل زمان پردازش
۳. تغییر اندازه فریم ها برای کاهش بار محاسباتی
۴. تبدیل فریم ها به تصویر خاکستری
۵. نرمال سازی شدت روشنایی
۶. اعمال CLAHE برای بهبود کنتراست محلی
۷. اعمال Gaussian Blur برای کاهش نویز
۸. انتخاب ناحیه مورد نظر یا ROI برای تمرکز روی سطح آب

استفاده از ROI اهمیت زیادی داشت، زیرا در بسیاری از ویدئوها بخش هایی مانند ساحل، درخت، پل، نمودار رنگی، افراد یا اجسام ثابت و متحرک در تصویر وجود داشتند. اگر این نواحی وارد محاسبات حرکتی می شدند، ویژگی های استخراج شده به جای حرکت آب، ترکیبی از حرکت آب و نویزهای محیطی را نشان می دادند.

در نتیجه، برای هر ویدئو ناحیه تقریبی آب مشخص شد و ویژگی های حرکتی فقط از همان ناحیه استخراج گردید.



#### ۵. آزمایش های اولیه

در مراحل اولیه، چند روش مختلف بررسی شد.

## ۵.۱. استخراج ویژگی در سطح کل ویدئو با Optical Flow

در اولین نسخه، از الگوریتم Farneback Dense Optical Flow برای محاسبه حرکت پیکسل‌ها بین فریم‌های متوالی استفاده شد. سپس برای هر ویدئو، ویژگی‌های آماری از میدان حرکت استخراج شد و هر ویدئو به یک بردار ویژگی تبدیل گردید.

ویژگی‌هایی که در این مرحله بررسی شدند شامل موارد زیر بودند:

- Mean Motion Magnitude
- Median Motion Magnitude
- Motion Percentile 75%
- Motion Percentile 90%
- Motion Percentile 95%
- Motion Standard Deviation
- Mean Horizontal Flow
- Mean Vertical Flow
- نسبت حرکت افقی به عمودی
- Motion Coherence
- Texture Feature
- Valid Motion Ratio

در این مرحله مدل‌های مختلف رگرسیون بررسی شدند و بهترین مدل اولیه RandomForest بود. نتیجه اولیه برای RandomForest به صورت زیر بود:

| روش                         | MAE (m/s) | RMSE (m/s) | MAPE (%) |
|-----------------------------|-----------|------------|----------|
| Optical Flow + RandomForest | 0.7099    | 1.3306     | 93.31    |

این نتیجه نشان داد که Optical Flow به تنهایی می‌تواند یک baseline اولیه ایجاد کند، اما خطا هنوز زیاد است.

## ۵.۲. افزودن KLT Feature Tracking

در مرحله بعد، برای بهبود استخراج حرکت، روش KLT Feature Tracking نیز به pipeline اضافه شد. Optical Flow متراکم، حرکت کلی پیکسل‌ها را محاسبه می‌کند، اما KLT نقاط شاخص و قابل ردیابی تصویر را دنبال می‌کند. در ویدئوهای آب، این نقاط می‌توانند شامل موج‌ها، ذرات روشن، الگوهای سطح آب یا بافت‌های متحرک باشند.

با اضافه کردن KLT، ویژگی‌های مکمل زیر استخراج شدند:

- تعداد نقاط قابل ردیابی
- میانگین حرکت نقاط KLT
- میانه حرکت نقاط KLT
- Percentile های حرکتی نقاط KLT
- نسبت حرکت افقی و عمودی
- پراکندگی حرکت نقاط
- پایداری حرکت نقاط

نتیجه پس از اضافه شدن KLT بهتر شد:

| روش                               | MAE (m/s) | RMSE (m/s) | MAPE (%) |
|-----------------------------------|-----------|------------|----------|
| Optical Flow + KLT + RandomForest | 0.6520    | 1.2979     | 83.03    |

این بهبود نشان داد که ترکیب Optical Flow و KLT نسبت به استفاده تنها از Optical Flow، اطلاعات حرکتی کامل‌تری از سطح آب استخراج می‌کند.

---

### ۳.۵. بررسی روش‌های مبتنی بر یادگیری عمیق

در طول انجام پروژه، امکان استفاده از مدل‌های یادگیری عمیق نیز بررسی شد. برای مثال، مدل‌های sequence-based مانند LSTM برای یادگیری تغییرات زمانی و همچنین ایده استفاده از مدل‌های segmentation عمیق برای جداسازی ناحیه آب بررسی شدند.

با این حال، به دلیل محدود بودن تعداد ویدئوهای دارای برچسب، تفاوت زیاد بین محیط‌ها، خاکستری بودن بسیاری از تصاویر، متفاوت بودن داده‌های حرارتی و نبود ground truth دقیق برای segmentation، این روش‌ها خروجی پایداری نداشتند و خطر overfitting در آن‌ها بالا بود.

در نتیجه، برای نسخه نهایی از یک روش سبک‌تر، قابل توضیح‌تر و مناسب‌تر برای دیتاست کوچک استفاده شد.

---

### ۶. روش نهایی پیشنهادی

روش نهایی پروژه بر اساس استخراج ویژگی در سطح پنجره‌های زمانی طراحی شد.

در نسخه‌های اولیه، هر ویدئو به یک بردار ویژگی تبدیل می‌شد. اما با توجه به تعداد کم ویدئوها، این کار باعث می‌شد مدل فقط با

۲۲ نمونه برچسب‌دار آموزش و ارزیابی شود. برای افزایش پایداری تخمین، هر ویدئو به چند پنجره زمانی کوتاه تقسیم شد و از

هر پنجره ویژگی‌های حرکتی استخراج گردید.

روند کلی روش نهایی به صورت زیر است:

Video



Frame Sampling



Preprocessing



ROI / Water Region Selection



Temporal Windowing



Dense Optical Flow + KLT Tracking



Feature Extraction per Window



RandomForest Regression



Window Predictions



Median Aggregation



Final Video-level Speed Prediction

در این روش، از هر پنجره زمانی یک بردار ویژگی استخراج می‌شود. سپس مدل برای هر پنجره یک مقدار سرعت پیش‌بینی می‌کند و در نهایت برای رسیدن به مقدار نهایی سرعت ویدئو، از میانه پیش‌بینی‌های پنجره‌ها استفاده می‌شود. استفاده از میانه نسبت به میانگین، مقاومت بیشتری در برابر پنجره‌های نویزی یا غیرعادی دارد.

---

## ۷. جلوگیری از Data Leakage

تقسیم ویدئو به چند پنجره زمانی، اگر به شکل نادرست انجام شود، می‌تواند باعث نشت اطلاعات شود. برای مثال، اگر برخی پنجره‌های یک ویدئو در train و برخی پنجره‌های همان ویدئو در test قرار بگیرند، مدل عملاً همان ویدئو را در مرحله آموزش دیده است و نتیجه ارزیابی بیش از حد خوش‌بینانه خواهد بود.

برای جلوگیری از این مشکل، در این پروژه ارزیابی نهایی به صورت Grouped Leave-One-Video-Out انجام شد. یعنی در هر مرحله، تمام پنجره‌های مربوط به یک ویدئو از داده آموزشی حذف شدند و همان ویدئو به عنوان داده آزمون استفاده شد.

به عبارت دیگر:

در هر مرحله:

Train → تمام پنجره‌های ۲۱ ویدئو

Test → تمام پنجره‌های ۱ ویدئو

این فرآیند برای همه ۲۲ ویدئوی دارای مقدار واقعی سرعت تکرار شد. بنابراین ارزیابی نهایی در سطح ویدئو انجام شد، نه در سطح پنجره، و از نشت اطلاعات بین train و test جلوگیری گردید.

---

## ۸. مدل‌های بررسی‌شده

برای تخمین سرعت جریان آب، چند مدل رگرسیون بررسی شدند:

- RandomForestRegressor
- ExtraTreesRegressor
- Ridge Regression
- Huber Regressor

با توجه به کوچک بودن دیتاست، وجود نویز، غیرخطی بودن رابطه بین ویژگی‌های تصویری و سرعت واقعی، و مقاومت نسبی مدل‌های ensemble در برابر داده‌های نویزی، مدل RandomForest به عنوان مدل نهایی انتخاب شد.

RandomForest برای این مسئله مناسب بود، زیرا:

۱. برای دیتاست‌های کوچک نسبتاً پایدارتر از مدل‌های عمیق است.

۲. توانایی مدل کردن روابط غیر خطی را دارد.

۳. نسبت به نویز و outlier ها تا حدی مقاوم است.

۴. نیاز به تنظیمات پیچیده و حجم زیاد داده ندارد.

۵. خروجی آن نسبتاً قابل تحلیل و قابل تکرار است.

---

## ۹. معیارهای ارزیابی

برای ارزیابی مدل از معیارهای زیر استفاده شد:

### MAE.۱.۹

MAE میانگین قدر مطلق خطاها را نشان می‌دهد و واحد آن همان واحد سرعت، یعنی متر بر ثانیه است. این معیار به عنوان معیار اصلی انتخاب شد، زیرا تفسیر آن ساده و مستقیم است.

$$MAE = \text{mean}(|\text{Real} - \text{Predicted}|)$$

### RMSE.۲.۹

RMSE یا Root Mean Squared Error نسبت به خطاهای بزرگ حساس تر است. این معیار برای بررسی اثر نمونه‌های دشوار و outlier ها مفید است.

$$RMSE = \sqrt{\text{mean}((\text{Real} - \text{Predicted})^2)}$$

### MAPE.۳.۹

MAPE خطای درصدی را نشان می‌دهد. با وجود مفید بودن این معیار، در این پروژه به عنوان معیار اصلی استفاده نشد، زیرا برخی سرعت‌های واقعی بسیار کوچک بودند؛ مانند  $0.141 \text{ m/s}$  یا  $0.384 \text{ m/s}$  در این حالت، حتی یک خطای مطلق متوسط می‌تواند باعث خطای درصدی بسیار بزرگ شود.

### R<sup>2</sup> Score.۴.۹

R<sup>2</sup> نیز می‌تواند برای بررسی میزان تطابق کلی پیش‌بینی با مقادیر واقعی استفاده شود، اما به دلیل کم بودن تعداد نمونه‌ها و وجود outlier های شدید، تمرکز اصلی گزارش روی MAE، RMSE و MAPE قرار گرفت.

در نهایت، MAE معیار اصلی گزارش در نظر گرفته شد و RMSE و MAPE به عنوان معیارهای کمکی استفاده شدند.

---



## ۱۰. نتایج مدل نهایی

در نسخه نهایی، تعداد نمونه‌های پنجره‌ای ساخته شده برابر با ۵۵۶ نمونه بود و از هر نمونه ۸۲ ویژگی استخراج شد.

Number of window samples: 556

Number of feature columns: 82

نتیجه مقایسه مدل‌ها در ارزیابی Grouped Leave-One-Video-Out به صورت زیر بود:

| مدل          | MAE (m/s) | RMSE (m/s) | MAPE (%) |
|--------------|-----------|------------|----------|
| RandomForest | 0.4773    | 1.1365     | 53.06    |
| ExtraTrees   | 0.4994    | 1.1227     | 59.14    |
| Ridge        | 0.6079    | 1.0654     | 89.73    |
| Huber        | 0.6627    | 1.0148     | 116.13   |

بر اساس معیار اصلی یعنی MAE، مدل RandomForest بهترین عملکرد را داشت و به عنوان مدل نهایی انتخاب شد.

نتیجه نهایی مدل منتخب:

Best model: RandomForest

MAE = 0.4773 m/s

RMSE = 1.1365 m/s

MAPE = 53.06 %

## ۱۱. روند بهبود مدل

در طول پروژه، روش پیشنهادی به صورت مرحله‌ای بهبود داده شد. ابتدا از Optical Flow در سطح کل ویدئو استفاده شد. سپس KLT Feature Tracking به آن اضافه شد. در نهایت با استفاده از Window-based Feature Extraction و اعتبارسنجی گروهی، نتیجه بهتر شد.

| مرحله                         | MAE (m/s) | RMSE (m/s) | MAPE (%) |
|-------------------------------|-----------|------------|----------|
| Optical Flow                  | 0.7099    | 1.3306     | 93.31    |
| Optical Flow + KLT            | 0.6520    | 1.2979     | 83.03    |
| Windowed + Optical Flow + KLT | 0.4773    | 1.1365     | 53.06    |

این نتایج نشان می‌دهد که اضافه کردن KLT و سپس استفاده از روش پنجره‌ای باعث بهبود قابل توجه عملکرد مدل شد. مقدار MAE از ۰.۷۰۹۹ به ۰.۴۷۷۳ متر بر ثانیه کاهش یافت.

## ۱۲. تحلیل خطا

برای تحلیل دقیق‌تر نتایج، خطای هر ویدئو بررسی شد. بیشترین خطا مربوط به چند نمونه خاص بود:

| ویدئو           | سرعت واقعی | سرعت پیش‌بینی شده | خطای مطلق | خطای درصدی |
|-----------------|------------|-------------------|-----------|------------|
| StJulien        | 6.001      | 1.1672            | 4.8338    | 80.55%     |
| Thalhofen       | 1.791      | 0.4300            | 1.3610    | 75.99%     |
| 1_Castor_Canada | 1.381      | 0.2396            | 1.1414    | 82.65%     |
| Tiber           | 2.331      | 1.3651            | 0.9659    | 41.44%     |
| 4_Castor_Canada | 0.141      | 1.0011            | 0.8601    | 610.00%    |

نمونه StJulien مهم‌ترین نمونه پرت دیتاست بود. سرعت واقعی این ویدئو ۶.۰۰۱ متر بر ثانیه است، در حالی که اکثر داده‌های دیگر در بازه سرعت پایین‌تر قرار دارند. به همین دلیل، مدل به دلیل کمبود نمونه‌های مشابه در بازه سرعت بالا، نتوانست این نمونه را به درستی تخمین بزند.

همچنین در نمونه ۴\_Castor\_Canada مقدار واقعی سرعت بسیار کوچک است. در چنین حالتی، خطای مطلق ۰.۸۶۰۱ m/s باعث خطای درصدی بسیار بزرگ، یعنی ۶۱۰٪ شده است. این موضوع نشان می‌دهد که MAPE در دیتاست‌هایی با مقادیر واقعی کوچک، معیار قابل اتکایی به عنوان معیار اصلی نیست.

## ۱۳. تحلیل حساسیت نسبت به نمونه‌های دشوار

برای بررسی اثر نمونه‌های پرت، معیارها در سه حالت محاسبه شدند:

| حالت ارزیابی                  | تعداد نمونه | MAE (m/s) | RMSE (m/s) | MAPE (%) |
|-------------------------------|-------------|-----------|------------|----------|
| همه ویدئوهای دارای برچسب      | 22          | 0.4773    | 1.1365     | 53.06    |
| بدون StJulien                 | 21          | 0.2698    | 0.4904     | 51.75    |
| بدون سه نمونه دشوار سرعت بالا | 19          | 0.1757    | 0.3453     | 51.02    |

این تحلیل نشان می‌دهد که بخش بزرگی از خطای مدل مربوط به چند نمونه دشوار است. با حذف StJulien، مقدار MAE از ۰.۴۷۷۳ به ۰.۲۶۹۸ کاهش یافت. همچنین با حذف سه نمونه دشوار StJulien، Tiber و Thalhofen، مقدار MAE به ۰.۱۷۵۷ متر بر ثانیه رسید.

این نتیجه نشان می‌دهد که روش پیشنهادی برای بخش عمده داده‌ها عملکرد مناسبی دارد، اما در برابر نمونه‌های خارج از توزیع اصلی داده و سرعت‌های بسیار بالا محدودیت دارد.

---

#### ۱۴. پیش‌بینی ویدئوهای بدون برچسب

دو ویدئو در دیتاست مقدار واقعی سرعت نداشتند. این ویدئوها در فرآیند آموزش و اعتبارسنجی استفاده نشدند. پس از انتخاب مدل نهایی، مدل RandomForest روی همه ویدئوهای دارای مقدار واقعی آموزش داده شد و سپس سرعت این دو ویدئو نیز پیش‌بینی شد.

برای این دو ویدئو، مقدار Predicted\_mps در خروجی ثبت شد، اما چون مقدار واقعی سرعت در دسترس نبود، Percent\_Error و Abs\_Error\_mps برای آن‌ها محاسبه نشد.

خروجی این بخش در فایل زیر ذخیره شد:

predictions\_windowed.csv

---

#### ۱۵. ثبت Log سرعت جریان در طول زمان

یکی از خروجی‌های مورد انتظار پروژه، ثبت Log سرعت تخمین زده شده در طول زمان بود. برای این منظور، ویدئوها به پنجره‌های زمانی تقسیم شدند و برای هر پنجره زمانی، سرعت جریان به صورت جداگانه تخمین زده شد.

این خروجی می‌تواند نشان دهد که مدل در طول زمان چه مقداری برای سرعت جریان تخمین می‌زند و آیا تخمین‌ها پایدار هستند یا خیر.

در خروجی‌های پروژه، برای هر ویدئو، اطلاعاتی مانند موارد زیر قابل ثبت است:

Name

win\_start

win\_end

predicted\_speed\_mps

Real\_mps

Abs\_Error\_mps


این فایل‌ها برای تحلیل زمانی رفتار مدل و بررسی پایداری تخمین سرعت در طول ویدئو قابل استفاده هستند.

## ۱.۶. نمودارهای تولیدشده برای تحلیل نتایج

برای تحلیل بهتر نتایج، چند نمودار تولید شد:


### ۱.۱.۶. Real vs Predicted

این نمودار مقدار واقعی سرعت را در برابر مقدار پیش‌بینی شده نشان می‌دهد. هرچه نقاط به خط  $y=x$  نزدیک‌تر باشند، مدل عملکرد بهتری دارد. این نمودار برای بررسی کلی کیفیت پیش‌بینی‌ها استفاده شد.




### ۲.۱.۶. نمودار خطای مطلق هر ویدئو

در این نمودار، خطای مطلق هر ویدئو نمایش داده شد. این نمودار به شناسایی نمونه‌های دشوار و outlierها کمک کرد.




### ۳.۱.۶. Residual Analysis

در این نمودار مقدار residual، یعنی اختلاف Predicted - Real، نسبت به سرعت واقعی رسم شد. این نمودار نشان داد مدل در سرعت‌های بالا تمایل به کم‌برآوردی دارد.



#### ۴.۱۶. نمودار حساسیت به outlierها

در این نمودار، مقدار MAE و RMSE در سه حالت همه داده‌ها، بدون St Julien، و بدون سه نمونه دشوار مقایسه شد. این نمودار نشان داد که بخش قابل توجهی از خطای مدل ناشی از نمونه‌های خاص و خارج از توزیع است.



#### ۵.۱۶. نمودار روند بهبود روش

این نمودار نشان داد که با حرکت از baseline ساده Optical Flow به نسخه KLT و سپس نسخه Windowed، عملکرد مدل بهتر شده است.

#### ۱۷. بررسی زمان پردازش و مشخصات سیستم

پردازش ویدئوها شامل خواندن فریم‌ها، محاسبه Optical Flow، اجرای KLT، استخراج ویژگی‌ها، آموزش مدل‌ها و ارزیابی Grouped Leave-One-Video-Out بود.

مشخصات سیستم مورد استفاده:

CPU: Intel(R) Core(TM) i7-7500U CPU @ 2.70GHz

RAM: 16 GB

OS: Windows 10

Python Version: 3.12.7

Libraries: OpenCV: 4.10.0, NumPy: 1.26.4, Pandas: 2.2.2, Scikit-learn: 1.5.1, Matplotlib: 3.9.2

زمان تقریبی پردازش:

زمان دقیق اجرای هر مرحله در اجرای اولیه به صورت جداگانه ثبت نشده بود؛ بنابراین زمان‌ها به صورت تقریبی گزارش می‌شوند. اجرای نسخه مبتنی بر Optical Flow + KLT روی سیستم CPU-only حدود چند ساعت زمان برد و اجرای نسخه نهایی window-based نیز به دلیل استخراج ویژگی از تعداد زیادی پنجره زمانی، محاسبه Optical Flow و KLT برای هر پنجره، و نبود GPU، زمان‌برتر بود. بخش عمده زمان اجرا مربوط به استخراج ویژگی‌های تصویری از ویدئوها بود و مرحله آموزش و ارزیابی مدل‌ها نسبت به آن زمان کمتری نیاز داشت.

---

## ۱۸. نقاط قوت روش پیشنهادی

روش پیشنهادی چند نقطه قوت اصلی دارد:

۱. قابل توضیح بودن روش نسبت به مدل‌های عمیق end-to-end
  ۲. مناسب بودن برای دیتاست کوچک
  ۳. استفاده از ROI برای کاهش اثر نواحی غیرمرتبط
  ۴. ترکیب Dense Optical Flow و KLT برای استخراج حرکت سطح آب
  ۵. استفاده از Windowing برای افزایش پایداری تخمین
  ۶. جلوگیری از data leakage با Grouped Leave-One-Video-Out
  ۷. تولید خروجی قابل تحلیل در سطح ویدئو و در طول زمان
  ۸. امکان تحلیل outlierها و شناسایی نقاط ضعف مدل
  ۹. قابلیت توسعه در صورت اضافه شدن داده بیشتر یا اطلاعات کالیبراسیون فیزیکی
-

## ۱۹. نقاط ضعف و محدودیت‌ها

با وجود بهبود نتایج، روش پیشنهادی محدودیت‌هایی نیز دارد:

۱. تعداد کم ویدئوهای دارای مقدار واقعی سرعت
۲. نبود اطلاعات کالیبراسیون فیزیکی مانند scale ، GSD، ارتفاع و زاویه دوربین
۳. ناهمگونی شدید ویدئوها از نظر سنسور، زاویه، نور و محیط
۴. حساسیت Optical Flow به نویز، بازتاب نور و حرکت‌های غیرمرتبط
۵. ضعف مدل در تخمین سرعت‌های خارج از توزیع آموزشی، مانند StJulien
۶. عدم استقلال کامل پنجره‌های زمانی یک ویدئو
۷. عدم امکان استفاده مؤثر از مدل‌های عمیق به دلیل کمبود داده
۸. دشواری جداسازی دقیق سطح آب در برخی ویدئوها
۹. وابستگی نسبی عملکرد مدل به کیفیت ROI انتخاب‌شده

---

## ۲۰. پیشنهادهای بهبود برای مراحل بعدی

برای بهبود عملکرد مدل در آینده، پیشنهادهای زیر قابل بررسی هستند:

۱. افزایش تعداد ویدئوهای دارای برچسب واقعی
۲. افزودن داده‌های بیشتر در بازه سرعت‌های بالا
۳. ثبت اطلاعات کالیبراسیون فیزیکی مانند GSD ، ارتفاع دوربین و زاویه دوربین
۴. استفاده از نقاط مرجع مکانی برای تبدیل pixel displacement به m/s
۵. استفاده از segmentation دقیق‌تر برای جداسازی سطح آب
۶. آموزش مدل‌های عمیق در صورت فراهم شدن دیتاست بزرگ‌تر
۷. استفاده از مدل‌های sequence-based مانند LSTM یا Transformer برای یادگیری مستقیم رفتار زمانی
۸. تفکیک مدل‌ها بر اساس نوع ویدئو، مانند FLIR ، seeded ، unseeded یا stabilized
۹. استفاده از روش‌های robust regression برای کاهش اثر outlier ها

## ۲۱. جمع‌بندی نهایی

در این پروژه، روشی برای تخمین سرعت جریان آب رودخانه با استفاده از پردازش تصویر و یادگیری ماشین ارائه شد. ابتدا دیتاست بررسی شد و چالش‌هایی مانند کمبود داده، ناهمگونی شرایط تصویربرداری، نبود کالیبراسیون فیزیکی و وجود نمونه‌های پرت شناسایی شدند.

در مرحله اول، یک baseline بر اساس Optical Flow طراحی شد. سپس برای بهبود استخراج حرکت سطح آب، KLT Feature Tracking به روش اضافه شد. در مرحله نهایی، برای افزایش پایداری تخمین، هر ویدئو به پنجره‌های زمانی تقسیم شد و از هر پنجره ویژگی‌های حرکتی استخراج گردید. برای جلوگیری از نشت اطلاعات، ارزیابی به صورت Grouped Leave-One-Video-Out انجام شد.

بهترین مدل نهایی RandomForest بود که روی ۵۵۶ نمونه پنجره‌ای و ۸۲ ویژگی استخراج‌شده ارزیابی شد. عملکرد نهایی مدل به صورت زیر بود:

MAE = 0.4773 m/s

RMSE = 1.1365 m/s

MAPE = 53.06 %

همچنین تحلیل خطا نشان داد که بخش عمده خطا مربوط به چند نمونه دشوار مانند StJulien، Thalhofen و Tiber است. با حذف نمونه پرت StJulien، مقدار MAE به ۰.۲۶۹۸ m/s کاهش یافت و با حذف سه نمونه دشوار سرعت بالا، مقدار MAE به ۰.۱۷۵۷ m/s رسید.

در مجموع، روش پیشنهادی به عنوان یک baseline قابل قبول و قابل توضیح برای دیتاست موجود عمل کرد، اما به دلیل محدودیت تعداد داده‌های برچسب‌دار، نبود اطلاعات کالیبراسیون و ناهمگونی شدید شرایط تصویربرداری، برای استفاده عملیاتی و صنعتی نیازمند داده‌های بیشتر، کالیبراسیون دقیق‌تر و توسعه بیشتر است.

---

## ۲۲. فایل‌های خروجی پروژه

خروجی‌های اصلی پروژه شامل موارد زیر هستند:

predictions\_windowed.csv

model\_comparison\_windowed.csv

evaluation\_summary\_windowed.txt



window\_features.csv

metrics\_summary.txt

real\_vs\_predicted plot

absolute error plot

outlier sensitivity plot

method improvement plot

speed logs over time

جدول ضمیمه پروژه با استفاده از فایل predictions\_windowed.csv تکمیل می شود. ستون های اصلی مورد استفاده در جدول عبارت اند از:

Name

Real\_mps

Eval\_Predicted\_mps

Abs\_Error\_mps

Percent\_Error

برای ویدئوهای بدون مقدار واقعی سرعت، فقط مقدار پیش بینی شده گزارش می شود و ستون های خطا خالی باقی می ماند.

---

## ۲۳. دستور اجرای پروژه

نمونه دستور ساخت ماسک و استفاده از klt:

```
python water_velocity.py --select_roi
```

```
python water_velocity.py
```

نمونه دستور اجرای pipeline نهایی:

```
python windowed_pipeline.py --sample_fps 8 --max_width 720 --window 2 --stride 1
```

یا

```
python src/windowed_pipeline.py --metadata "Validation Numbers.csv" --video_dir data/videos --  
mask_dir masks --out_dir outputs_windowed_pipeline --sample_fps 10 --max_width 960 --window 2 --  
stride 1
```

نمونه دستور تولید نمودارها:

```
python src/make_report_plots.py --predictions outputs_windowed_pipeline/predictions_windowed.csv  
--models outputs_windowed_pipeline/model_comparison_windowed.csv --out_dir report_plots
```

نمونه دستور تحلیل خطا:

```
python src/analyze_errors.py
```

نمونه دستور ساخت log:

```
python make_window_speed_logs.py --window_features  
"outputs_windowed_pipeline/window_features.csv" --out_dir "  
outputs_windowed_pipeline/window_speed_logs"
```

**Project Repository:**

<https://github.com/ztahmasbi77/water-velocity>